

# REGRESIÓN LINEAL

## 1. ¿Qué es la regresión?

La regresión es una técnica estadística cuyo objetivo es estudiar y cuantificar la relación entre variables. Permite responder preguntas como:

- ¿Si se conoce X, es posible estimar Y?
- ¿Existe relación entre dos variables?
- ¿Cómo cambia Y cuando cambia X?

La regresión se utiliza para explicar y predecir fenómenos. Algunos ejemplos:

- Relación entre inversión en publicidad y ventas.
- Relación entre tamaño de una vivienda y su precio.
- Relación entre edad y presión arterial.

En toda regresión existen dos variables:

- **Variable dependiente (Y):** la que se desea predecir.
- **Variable independiente (X):** la que se usa para realizar la predicción.

## 2. ¿Qué es una función lineal?

Una función lineal describe una relación proporcional mediante la expresión:

$$y = mx + b$$

Donde:

- **m** es la pendiente, que indica cuánto cambia 'y' cuando 'x' aumenta una unidad.
- **b** es el intercepto, que representa el valor de 'y' cuando  $x = 0$ .

Una función lineal es una ecuación predefinida, no proviene de datos empíricos.

## 3. Modelo lineal con término de error

En estadística se considera que la relación entre X y Y no es perfecta. Por ello, el modelo teórico incorpora un término que recoge toda la variabilidad no explicada por X:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Donde:

- $\beta_0$  es el verdadero intercepto de la población.
- $\beta_1$  es la verdadera pendiente de la población.
- $\varepsilon$  es el término de error, que recoge:
  - factores no medidos,
  - variabilidad aleatoria,
  - ruido o imprecisiones en la medición.

Este modelo expresa que Y depende de X y además de múltiples factores no observados representados por  $\varepsilon$ .

## 4. Recta de regresión estimada

Dado que  $\beta_0$  y  $\beta_1$  son desconocidos, se estiman a partir de datos. La recta estimada se expresa como:

$$y^{\wedge} = mx + b$$

Donde:

- $y^{\wedge}$  es el valor estimado o predicho.
- $m$  es la estimación de la pendiente  $\beta_1$ .
- $b$  es la estimación del intercepto  $\beta_0$ .

Los residuos se definen como:

$$e_i = y_i - y_i^{\wedge}$$

Y representan el error entre los valores observados y los estimados.

## 5. Criterio de ajuste: Mínimos Cuadrados Ordinarios (OLS)

La regresión lineal elige la recta que minimiza la suma total de los errores al cuadrado:

$$\sum (y_i - y_i^{\wedge})^2$$

Se eleva el error al cuadrado para:

- Evitar que errores positivos y negativos se cancelen.
- Penalizar más los errores grandes.

Este método se conoce como Mínimos Cuadrados Ordinarios (OLS).

## 6. Ejemplo detallado: cálculo de la pendiente

Se utiliza el siguiente conjunto de datos:

X	Y
1	2
2	3
3	5

La ecuación estimada tendrá la forma:  $y^{\wedge} = mx + b$

### Paso 1: Calcular promedios

$$\text{Promedio } X = (1+2+3) / 3 = 2$$

$$\text{Promedio } Y = (2+3+5) / 3 = 3.33$$

### Paso 2: Calcular la pendiente m

La pendiente se obtiene mediante la siguiente fórmula:

$$m = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

#### a) Desviaciones respecto a los promedios

X	Y	x - prom(x)	y - prom(y)
1	2	-1	-1.33
2	3	0	-0.33
3	5	1	1.67

**b) Productos de desviaciones (Numerador)**

X	Y	Producto
1	2	1.33
2	3	0
3	5	1.67
	<b>SUMA:</b>	<b>3</b>

Suma del numerador = 3

**c) Cuadrados de las desviaciones (Denominador)**

X	x - prom(x)	Cuadrado
1	-1	1
2	0	0
3	1	1
	<b>SUMA:</b>	<b>2</b>

Suma del denominador = 2

**d) Pendiente final**

$$m = 3 / 2 = 1.5$$

**Paso 3: Calcular el intercepto b**

$$b = \text{Promedio Y} - (m * \text{Promedio X})$$

$$b = 3.33 - (1.5 * 2)$$

$$b = 0.33$$

**7. Recta de regresión final**

$$y^{\wedge} = 1.5x + 0.33$$

**Interpretación:**

- Por cada aumento de 1 unidad en X, Y aumenta en promedio 1.5 unidades.
- Cuando X = 0, el valor estimado de Y es aproximadamente 0.33.

**8. Calidad del ajuste: coeficiente R<sup>2</sup>**

El coeficiente de determinación R<sup>2</sup>:

- Toma valores entre 0 y 1.
- Indica qué porcentaje de la variación de Y es explicado por el modelo.

**Ejemplo:**  $R^2 = 0.85$  significa que el 85% de la variación observada en Y puede explicarse mediante X. Cuanto más se aproxime a 1, mejor es el ajuste del modelo.